

PROFISSÃO: CIENTISTA DE DADOS

# Ciclo de vida de um modelo de machine learning

Regressão logística aplicada à previsão de cancelamento de clientes (churn)

|           |                                             |
|-----------|---------------------------------------------|
| Aluna     | Kessia                                      |
| Atividade | Exercício - Módulo 29                       |
| Tema      | Sete etapas do desenvolvimento de um modelo |

Este documento apresenta um exemplo hipotético, desenvolvido para fins acadêmicos.

## Visão geral do projeto

Uma empresa de serviços por assinatura deseja reduzir a perda de clientes. Para isso, será construído um modelo de regressão logística capaz de estimar a probabilidade de cada cliente cancelar o serviço nos próximos 30 dias. O resultado apoiará uma ação preventiva do time de retenção, priorizando clientes de maior risco sem substituir a análise humana.

A variável-alvo será binária: 1 quando o cliente cancelar dentro da janela definida e 0 quando permanecer ativo. A regressão logística é adequada porque produz uma probabilidade entre 0 e 1, permite definir um limiar de decisão conforme o custo da ação e oferece coeficientes interpretáveis.

|          |                            |        |                        |
|----------|----------------------------|--------|------------------------|
| Objetivo | Antecipar churn em 30 dias | Modelo | Regressão logística    |
| Unidade  | Cliente ativo              | Saída  | Probabilidade de churn |
| Uso      | Priorização de campanhas   | Janela | Próximos 30 dias       |

### 1 Coleta de dados

Seriam reunidos dados internos autorizados e necessários ao objetivo: cadastro e tempo de relacionamento, plano contratado, valor da mensalidade, histórico de pagamentos, chamados de suporte, reclamações, uso do produto e interações com campanhas. A data do cancelamento permitiria construir o alvo sem utilizar informações posteriores ao momento da previsão.

A coleta teria uma data de referência por cliente. As variáveis explicativas seriam calculadas somente com fatos conhecidos até essa data; o rótulo indicaria se ocorreu cancelamento nos 30 dias seguintes. Esse desenho evita vazamento de dados. Também seriam definidos dicionário das variáveis, origem, periodicidade, responsável e regras de acesso, com minimização de dados pessoais e respeito à LGPD.

Antes de seguir, seriam avaliados cobertura temporal, duplicidades, chaves de integração, estabilidade das fontes e representatividade. Um período de 12 a 24 meses ajudaria a capturar sazonalidade, mudanças de preço e diferentes perfis de clientes.

### 2 Preparação dos dados

As tabelas seriam integradas pela chave do cliente e pela data de referência. Registros duplicados seriam removidos, tipos de dados corrigidos e valores impossíveis investigados. Ausências receberiam tratamento coerente: por exemplo, zero chamados pode significar ausência de contato, enquanto mensalidade ausente exige correção na fonte ou imputação documentada.

Seriam criadas variáveis úteis, como dias desde o último acesso, frequência de uso nos últimos 30 e 90 dias, atraso médio de pagamento, quantidade recente de chamados, variação do uso, tempo de contrato e relação entre reclamações e meses de permanência. Variáveis categóricas, como tipo de plano e canal de aquisição, seriam codificadas; variáveis numéricas poderiam ser padronizadas para facilitar regularização e comparação de coeficientes.

Os dados seriam separados cronologicamente em treino, validação e teste, preservando no teste o período mais recente. Qualquer imputação, padronização ou codificação seria ajustada apenas no treino e aplicada aos demais conjuntos por um pipeline. Se o churn fosse raro, seriam usados pesos de classe ou técnicas de reamostragem somente no conjunto de treino.

### **3 Escolha do modelo**

A regressão logística seria escolhida como modelo principal porque o alvo é binário e o negócio precisa tanto de uma classificação quanto de uma probabilidade de risco. Ela é rápida, reproduzível e relativamente interpretável: o sinal e a magnitude dos coeficientes ajudam a entender como cada variável se relaciona com a chance de cancelamento.

A escolha não seria baseada apenas em simplicidade. O modelo funcionaria como linha de base e seria comparado a uma regra ingênua e, se necessário, a modelos mais flexíveis já estudados, como árvore de decisão. Se a alternativa mais complexa trouxesse ganho pequeno e perdesse transparência, a regressão logística poderia ser preferida. Também seriam verificadas multicolinearidade, relações não lineares relevantes e possíveis interações.

### **4 Treinamento do modelo**

O pipeline de preparação seria ajustado no conjunto de treino e, em seguida, a regressão logística aprenderia os coeficientes que minimizam a função de perda logarítmica. A regularização L1 ou L2 seria utilizada para reduzir sobreajuste e controlar coeficientes muito altos, especialmente quando existirem muitas variáveis correlacionadas.

O treinamento seria reproduzível: versão dos dados, código, parâmetros, semente aleatória e métricas seriam registrados. A validação cruzada com divisão temporal ou uma validação fora do tempo ajudaria a selecionar hiperparâmetros sem tocar no conjunto de teste. O limiar inicial de 0,50 não seria aceito automaticamente; ele seria tratado como uma decisão de negócio a ser definida na avaliação.

## 5 Avaliação do modelo

A avaliação começaria no conjunto de validação e seria confirmada uma única vez no teste temporal. Como o churn pode ser desbalanceado, acurácia isolada seria inadequada. Seriam analisadas matriz de confusão, precisão, recall, F1, curva ROC-AUC e principalmente PR-AUC. A calibração também seria medida, pois uma probabilidade prevista de 0,70 deve representar aproximadamente 70% de cancelamentos em grupos semelhantes.

O limiar seria escolhido a partir do custo dos erros e da capacidade da equipe. Um falso negativo deixa de abordar um cliente que cancelará; um falso positivo consome recurso ou oferece desconto desnecessário. Assim, seria possível escolher, por exemplo, um ponto que maximize o recall mantendo precisão aceitável e um volume semanal compatível com a operação.

As métricas seriam segmentadas por plano, região, tempo de relacionamento e outros grupos relevantes para detectar quedas de desempenho ou tratamento desigual. Também seriam comparados o ganho acumulado e o lift dos decis de maior risco, mostrando quantos cancelamentos podem ser encontrados quando apenas uma parte da base recebe ação.

## 6 Ajuste e otimização

Com base na validação, seriam testados os parâmetros de regularização, pesos das classes, seleção de variáveis, transformações e interações justificáveis. A busca poderia usar grade ou amostragem aleatória dentro de um pipeline, avaliando cada configuração com a mesma estratégia temporal. O critério combinaria PR-AUC, calibração, estabilidade e impacto financeiro esperado.

A otimização incluiria análise de erros. Falsos negativos poderiam revelar sinais que ainda não foram coletados; falsos positivos poderiam indicar campanhas anteriores ou clientes com perfil atípico. Variáveis com risco de vazamento seriam removidas. Se necessário, as probabilidades seriam recalibradas. O limiar final seria escolhido após uma simulação de custo-benefício, considerando margem, custo do contato e taxa esperada de sucesso da retenção.

O processo teria um ponto de parada: ganho marginal pequeno, instabilidade entre períodos ou perda de interpretabilidade seriam motivos para não aumentar a complexidade. O conjunto de teste permaneceria protegido para evitar que sucessivas tentativas produzissem uma estimativa otimista.

## 7 Implantação e monitoramento

O pipeline completo seria publicado para gerar probabilidades em lote, por exemplo diariamente ou semanalmente. Cada saída conteria identificador interno, data da pontuação, probabilidade, faixa de risco e versão do modelo. A lista de maior risco seguiria para o sistema de relacionamento com regras claras de uso. Antes da liberação ampla, um piloto ou teste A/B verificaria se a ação guiada pelo modelo realmente reduz churn.

Em produção, seriam monitorados qualidade e atraso das fontes, percentuais de valores ausentes, distribuição das variáveis, estabilidade das probabilidades, volume por faixa de risco, latência e

falhas do pipeline. Quando os rótulos chegassem, seriam recalculados precisão, recall, PR-AUC, calibração, lift e resultado financeiro. Drift de dados, queda de desempenho ou mudança no negócio acionariam investigação.

Também haveria controle de versão, logs, documentação, responsáveis, plano de contingência e possibilidade de retornar à versão anterior. O retreinamento poderia ocorrer em calendário definido ou por gatilhos de degradação, sempre passando por nova validação antes da substituição. Por fim, o modelo seria auditado quanto a vieses e uso indevido, e dados pessoais seriam protegidos durante todo o ciclo.

## Conclusão

O projeto não termina quando o modelo alcança uma boa métrica. O valor surge quando a previsão é construída sem vazamento, traduzida em uma decisão operacional, testada no mundo real e acompanhada ao longo do tempo. No caso proposto, a regressão logística oferece um equilíbrio adequado entre desempenho, probabilidade calibrável e interpretação. As sete etapas formam um ciclo contínuo: o monitoramento de produção gera novos aprendizados, que voltam à coleta, preparação e evolução responsável do modelo.